

Mapeamento Causal e Grafos Acíclicos Direcionados (DAGs) na Análise de Dados e Tomada de Decisão

1. Introdução à Inferência Causal e Fundamentos do Mapeamento de Premissas

A modelagem analítica contemporânea enfrenta uma limitação estrutural inerente à inferência estatística clássica: a fusão indevida entre padrão associativo e relação causal. Na gestão baseada em dados, estimar a probabilidade condicional $P(Y | X)$ descreve unicamente o comportamento passivo de uma variável de resposta Y dada a observação da variável X em determinado estado. No entanto, a tomada de decisão executiva e a formulação de estratégias operacionais exigem a avaliação do impacto de intervenções ativas sobre o sistema, representada formalmente pelo operador *do* de Pearl, $P(Y | do(X))$. A expansão da volumetria de dados no paradigma de Big Data reduz a variância amostral ($\sigma / \sqrt{n} \rightarrow 0$), mas preserva inalterado o viés estrutural ou erro sistemático ($E[\theta] - \theta_0 \neq 0$). Consequentemente, o aumento de escala computacional sem uma arquitetura causal subjacente apenas confere elevada precisão estatística a estimativas conceitualmente equivocadas.

Para mitigar tais falhas e evitar a alocação ineficiente de capital, o mapeamento *a priori* das premissas causais deve anteceder a etapa de processamento e modelagem estatística. Sob a perspectiva da arquitetura de dados e da engenharia de atributos (*feature engineering*), definir o mecanismo gerador de dados garante que os pipelines analíticos (como transformações via SQL, dbt ou Airflow) não introduzam artefatos de viés antes da fase de estimação. A formalização gráfica das premissas delinea explicitamente os caminhos de transmissão de variação, isolando associações espúrias de efeitos operacionais reais.

Eixo	Análise Observacional / Correlacional	Inferência Causal baseada em DAGs
Objetivo	Mapear associações estatísticas observadas e prever valores condicionalmente ($P(Y X)$).	Identificar e quantificar o efeito causal total e direto de intervenções ativas ($P(Y do(X))$).
Premissas Explícitas	Pressupõe ausência de confusão ou estabilidade distributiva sem mapeamento formal.	Formaliza <i>a priori</i> a topologia do mecanismo gerador de dados e suas dependências estatísticas.
Risco de Viés	Elevado; vulnerável ao viés de confusão, viés de colisão e paradoxo de Simpson.	Minimizado; garante a seleção rigorosa de variáveis de ajuste via d-separação e critério backdoor.

Eixo	Análise Observacional / Correlacional	Inferência Causal baseada em DAGs
Capacidade de Intervenção	Nula ou limitada; correlações tendem a colapsar sob intervenções diretas no sistema.	Elevada; permite a simulação contrafactual e a previsão do impacto real de mudanças operacionais.

A necessidade de formalizar rigorosamente essa representação estrutural e quantificar intervenções contrafactuais conduz à fundamentação matemática dos Grafos Acíclicos Direcionados (DAGs).


2. Anatomia e Teoria Formal dos Grafos Acíclicos Direcionados (DAGs)

Os Grafos Acíclicos Direcionados (DAGs) fornecem uma linguagem formal e não paramétrica para codificar hipóteses causais e governar a modelagem estatística. Um DAG é denotado formalmente por um par $G = (V, E)$, onde V representa o conjunto de vértices ou nós, e E representa o conjunto de arestas direcionadas. A base lógica dos DAGs assenta-se nos Modelos Causais Estruturais (SCMs, *Structural Causal Models*) ou Equações Estruturais Não Paramétricas (NPSEMs). Em um SCM, cada variável observável $V_i \in V$ é gerada por uma função determinística não paramétrica:

$$V_i = f_i(PA_i, U_i), \quad i = 1, \dots, n$$

onde $PA_i \subseteq V \setminus \{V_i\}$ denota o conjunto de pais diretos de V_i no grafo, e U_i representa o termo de erro exógeno ou ruído estocástico não observado, assumido mutuamente independente na ausência de *confounders* não mensurados.

SCM / Modelo Causal Estrutural:



Os componentes formais e as propriedades topológicas de um DAG $G = (V, E)$ são definidos rigidamente por:

- **Nós (Nodes/Variables V):** representam os atributos ou variáveis do sistema, dividindo-se entre variáveis observadas (V) e variáveis não observadas/latentes (U).
- **Arestas Direcionadas (Directed Edges E):** pares ordenados $(X, Y) \in E$, graficamente representados como $X \rightarrow Y$, indicando que X é uma causa direta de Y no sistema funcional do mundo real.
- **Fluxo Causal e Aciclicidade:** a topologia do grafo proíbe estritamente a existência de caminhos direcionados fechados (isto é, $X \rightarrow \dots \rightarrow X$). Essa propriedade garante a assimetria temporal da causalidade, impedindo loops de feedback instantâneos ($t_{causa} < t_{efeito}$).

As relações operacionais no grafo determinam a dependência condicional entre as variáveis:

- **Pais (PA_i):** $PA_i = \{ X \in V \mid (X, V_i) \in E \}$. O conjunto de nós de onde partem setas diretas para V_i .

- **Filhos (CH_i):** $CH_i = \{ Y \in V \mid (V_i, Y) \in E \}$. O conjunto de nós para os quais incidem setas diretas vindas de V_i .
- **Ancestrais (AN_i):** o conjunto de nós a partir dos quais existe pelo menos um caminho direcionado que alcança V_i .
- **Descendentes (DE_i):** o conjunto de nós que podem ser alcançados por um caminho direcionado a partir de V_i . Por definição, $V_i \notin DE_i$.

Na arquitetura de sistemas e modelos analíticos, a estrutura de um DAG mapeia-se diretamente na linhagem de dados (*data lineage*). Pipelines de transformação ou *feature stores* devem respeitar a topologia acíclica para evitar vazamento de dados (*data leakage*) e condicionamentos indesejados. Estes componentes combinam-se estruturalmente para formar os três blocos topológicos primários do raciocínio causal.

3. As Três Estruturas Causais Fundamentais e Seus Impactos no Viés

Toda a complexidade de um DAG pode ser decomposta em três microestruturas elementares. Cada topologia dita uma regra estatística estrita para inclusão, ajuste ou exclusão de variáveis em modelos de regressão ou algoritmos de aprendizado de máquina.

1. Confundidor:	$A \leftarrow C \rightarrow B$	(Causa comum; ajuste OBRIGATÓRIO)
2. Mediador:	$A \rightarrow M \rightarrow B$	(Mecanismo de transmissão; NÃO ajustar para efeito total)
3. Colisor:	$A \rightarrow K \leftarrow B$	(Efeito comum; NÃO ajustar / NÃO filtrar)

3.1 Confundidores (Confounders — Estrutura $A \leftarrow C \rightarrow B$)

O viés de confusão surge quando uma variável C opera como causa comum de A (tratamento) e B (resposta). A presença de C estabelece um caminho não causal (*backdoor path*) aberto $A \leftarrow C \rightarrow B$, que infunde uma associação espúria nos dados, mascarando a real magnitude de $P(Y \mid do(X))$. O ajuste ou condicionamento estatístico em C é estritamente obrigatório para bloquear a transferência de variação não causal e isolar o verdadeiro efeito causal de A sobre B .

3.2 Mediadores (Mediators — Estrutura $A \rightarrow M \rightarrow B$)

O mediador M é uma variável intermediária através da qual o efeito do tratamento A se propaga até B . No âmbito da decomposição de efeitos, distingue-se o **Efeito Causal Total** (o impacto global da intervenção A sobre B , agregando vias diretas e indiretas) do **Efeito Causal Direto** (a parcela do efeito de A sobre B que não é transmitida por M). Se o objetivo analítico ou decisório for quantificar o efeito total de uma intervenção, o condicionamento em M constitui um erro metodológico grave, pois bloqueia o próprio canal físico de transmissão da intervenção.

3.3 Colisores (Colliders — Estrutura $A \rightarrow K \leftarrow B$)

O viés de colisão (*Collider Bias* ou Paradoxo de Berkson) ocorre quando duas causas A e B , condicionalmente independentes no mecanismo gerador, convergem para um nó comum K . Por definição topológica, a estrutura $A \rightarrow K \leftarrow B$ está naturalmente bloqueada, impedindo a transmissão de associação não causal. O erro analítico surge quando o

pesquisador condiciona, controla ou filtra a amostragem pela variável colisora K (ou por qualquer um de seus descendentes DE_K). Esse condicionamento força a abertura do caminho espúrio, gerando correlações ilusórias entre A e B ($A \not\perp B \mid K$).

Formalização do Causal Graph Bridging: d-Separação e d-Conexão

A ponte matemática rigorosa entre a topologia do grafo G e a distribuição de probabilidade observada P é estabelecida pelo critério de d-separação (separação direcionada), concebido por Judea Pearl.

Definição (d-separação): um caminho p entre dois nós X e Y em um DAG G é dito *bloqueado* por um conjunto de nós Z se, e somente se, pelo menos uma das seguintes condições for satisfeita:

1. O caminho contém uma cadeia $I \rightarrow M \rightarrow J$ ou um garfo $I \leftarrow M \rightarrow J$ tal que o nó intermediário M pertence ao conjunto Z ($M \in Z$).
2. O caminho contém um colisor $I \rightarrow K \leftarrow J$ tal que o nó K não pertence ao conjunto Z ($K \notin Z$) e nenhum descendente de K pertence a Z ($DE_K \cap Z = \emptyset$).

Se o conjunto Z bloqueia todos os caminhos entre X e Y no grafo G , diz-se que X e Y são d-separados por Z , denotado por $(X \perp\!\!\!\perp_G Y \mid Z)$. A d-separação implica diretamente a independência condicional na distribuição de probabilidade:

$$(X \perp\!\!\!\perp_G Y \mid Z) \implies (X \perp\!\!\!\perp_P Y \mid Z)$$

Se os nós não forem d-separados, eles são d-conectados, permitindo o fluxo de associação estatística entre si.

d-Separação / Bloqueio de Caminhos por Z:

Cadeia Bloqueada: $I \dashrightarrow [M \in Z] \dashrightarrow J$ (Bloqueado por M)
 Garfo Bloqueado: $I \dashleftarrow [M \in Z] \dashrightarrow J$ (Bloqueado por M)
 Colisor Fechado: $I \dashrightarrow (K \notin Z) \dashleftarrow J$ (Bloqueado naturalmente por K)
 Colisor ABERTO: $I \dashrightarrow [K \in Z] \dashleftarrow J$ (D-CONECTADO! Gera viés de colisão)

Tabela Resumo de Decisão de Controle Causal

Estrutura Topológica	Descrição da Relação	Ação sobre a Variável	Sequela de uma Decisão Errada
Confundidor ($A \leftarrow C \rightarrow B$)	C é causa comum de A e B.	Controlar / Ajustar	Viés de Confusão: atribuição incorreta da variação de B ao tratamento A.
Mediador ($A \rightarrow M \rightarrow B$)	M transmite o efeito de A para B.	Não controlar (para efeito total)	Subestimativa de Efeito: anulação do mecanismo de transmissão da intervenção.
Colisor ($A \rightarrow K \leftarrow B$)	K é efeito comum de A e B.	Não controlar / Não filtrar	Viés de Colisão / Berkson: indução de correlação ilusória entre variáveis independentes.

A aplicação do rigor da d-separação aos grafos complexos possibilita a operacionalização de algoritmos para identificação do efeito causal.

4. Critérios de Controle Estatístico e Identificação de Caminhos Backdoor

A prática intuitiva de incluir o maior número possível de variáveis observadas em um modelo estatístico (“modelo *kitchen sink*”) constitui uma abordagem analítica falha. O aumento desorientado de covariáveis frequentemente resulta no condicionamento involuntário de colisores ou mediadores, violando a identificabilidade do efeito causal e inflando a variância dos estimadores.

Um **Caminho Backdoor** é qualquer trajetória não direcionada entre o nó de tratamento X e o nó de resposta Y que se inicia com uma seta apontando para X ($X \leftarrow \dots Y$). Esses caminhos transmitem associações puramente espúrias decorrentes de causas comuns não controladas.

Caminho Backdoor Contaminante:

[X (Tratamento)] <--- [C (Confundidor)] ---> [Y (Resposta)]

(Deve ser bloqueado ajustando por C)

O Critério Backdoor (Pearl)

Para mitigar a contaminação e isolar $P(Y \mid do(X))$, seleciona-se um conjunto de variáveis de ajuste S .

Definição Formal do Critério Backdoor: um conjunto de variáveis $S \subset V$ satisfaz o Critério Backdoor relativo a um par ordenado de variáveis (X, Y) em um DAG G se:

1. Nenhum nó em S for descendente do tratamento X ($S \cap DE_X = \emptyset$); e
2. O conjunto S d-separa X de Y no grafo modificado $G_{\bar{X}}$, derivado de G através da remoção de todas as arestas direcionadas que partem de X .

Satisfazendo o Critério Backdoor, o efeito causal interventivo é identificado não parametricamente pela **Fórmula de Ajuste de Pearl**:

$$P(Y = y \mid do(X = x)) = \sum_s P(Y = y \mid X = x, S = s) \cdot P(S = s)$$

Grafo Modificado $G_{\bar{X}}$:

Setas saindo de X são eliminadas.

Se S d-separa X de Y em $G_{\bar{X}}$, S satisfaz o Critério Backdoor.

Ferramentas Computacionais e Testabilidade (DAGitty)

A verificação algébrica e topológica em grafos de alta dimensão torna-se inviável manualmente. O uso de bibliotecas de inferência causal, como a ferramenta computacional DAGitty, automatiza essa validação. O DAGitty processa a topologia do grafo G para:

- identificar algoritmicamente os Conjuntos Mínimos de Ajuste (*minimal adjustment sets*);
- mapear todos os caminhos backdoor abertos e fechados;

- derivar o conjunto de Implicações Testáveis de Independência Condicional em G (as d-separações).

Essas implicações permitem confrontar a hipótese gráfica com os dados empíricos observados (por exemplo, testando via testes de independência estatística se $X \perp\!\!\!\perp Y \mid Z$ na matriz de covariância), validando ou refutando a arquitetura do SCM proposto antes de subsidiar decisões estratégicas de negócio.


5. Casos de Uso Práticos no E-Commerce e Gestão de Negócios

No ambiente de e-commerce e produtos digitais, a tomada de decisão com base em associações correlacionais frequentemente leva à destruição de margem financeira e ao direcionamento incorreto de recursos estratégicos.

5.1 Avaliação do Impacto de Cupons de Desconto na Margem/LTV

Um problema recorrente nas operações de e-commerce envolve quantificar se a concessão de um cupom de desconto (A) aumenta o *Lifetime Value* (LTV) ou a Margem do cliente (B). No entanto, o engajamento prévio do cliente (C) atua como um confundidor: clientes mais engajados buscam ativamente por cupons de desconto e, simultaneamente, já apresentam uma tendência natural a consumir mais e gerar maior LTV.

DAG 5.1: Cupons de Desconto e LTV




Sem o ajuste adequado por C , o efeito aparente do cupom absorve a variação do engajamento prévio, inflando a eficácia aparente do incentivo e fazendo a empresa subsidiar transações que ocorreriam espontaneamente.

5.2 Análise de Eficiência de Programas de Fidelidade

Ao mensurar o impacto da adesão a um programa de fidelidade (A) nas vendas totais (B), a intenção de compra prévia do usuário (C) funciona como causa comum (confundidor). Por outro lado, o engajamento e a frequência de compras pós-adesão (M) operam como um mediador do efeito ($A \rightarrow M \rightarrow B$).

DAG 5.2: Programa de Fidelidade e Vendas




Se o time de Analytics condicionar os modelos estatísticos pelo engajamento pós-adesão (M) durante o processo de *feature engineering*, bloqueará a principal via de transmissão causal do tratamento, concluindo erroneamente que o programa de fidelidade é ineficiente.

5.3 Decisões de Precificação Dinâmica e Elasticidade-Preço

Na estimativa do efeito do preço praticado (A) sobre o volume de vendas (B), a sazonalidade e a demanda de mercado (C) atuam como confundidores críticos. Em datas comemorativas ou picos de demanda, os algoritmos de preços elevam a tarifa (A) e, simultaneamente, o volume consumido (B) cresce impulsionado pela sazonalidade (C).

DAG 5.3: Precificação Dinâmica e Elasticidade



A omissão do ajuste por C produz uma estimativa observacional com viés positivo, sugerindo erroneamente uma “elasticidade-preço positiva” (aumento de preço associado a aumento de vendas), o que violaria os princípios microeconômicos básicos e levaria a precificações desastrosas.

Quadro Explicativo: Decisões Estratégicas e Estruturas Causais

Cenário de Negócio	Hipótese Causal Incorreta (Visão Correlacional)	Estrutura Causal Oculta (DAG)	Decisão Estratégica Correta
Cupons de Desconto vs. LTV	Cupons geram incremento direto no LTV do usuário.	Confundidor: engajamento prévio (C) impulsiona cupons (A) e LTV (B).	Ajustar por C: bloquear o caminho backdoor para mensurar a verdadeira margem incremental do cupom.
Programa de Fidelidade	O programa não gera impacto incremental nas vendas.	Mediador: engajamento pós-adesão (M) transmite o efeito do programa (A).	Não ajustar por M: preservar o mediador no modelo para capturar o Efeito Causal Total.
Precificação Dinâmica	Elevações de preço aumentam o volume de vendas.	Confundidor: sazonalidade/demanda (C) afeta o preço (A) e as vendas (B).	Ajustar por C: bloquear os picos de demanda para recuperar a curva de elasticidade-preço negativa real.

A constatação empírica dessas dinâmicas reforça a urgência de institucionalizar a modelagem causal nos fluxos de dados corporativos.

6. Recomendações Práticas e Conclusão

A implementação de inferência causal e Grafos Acíclicos Direcionados deve integrar a infraestrutura de dados e os processos analíticos como um padrão metodológico permanente.

Guia de Implementação para Times de Ciência de Dados e Arquitetura de Dados

- Mapeamento Causal a Priori:** antes de formular consultas SQL ou treinar modelos preditivos, construa explicitamente o DAG referente ao problema de negócio, identificando o mecanismo gerador de dados subjacente.

2. **Formalização em SCM e Classificação de Variáveis:** converta o grafo causal em um SCM e classifique topologicamente cada covariável em confundidor, mediador ou colisor relativo ao tratamento e à resposta.
3. **Identificação do Conjunto Mínimo de Ajuste:** utilize o critério de d-separação e a regra backdoor (via algoritmos como DAGitty) para isolar o conjunto estrito de variáveis que devem ser incluídas no modelo, evitando a inclusão desnecessária de variáveis.
4. **Governança em Pipelines de Dados e Feature Stores:** modele as transformações em dbt/Airflow e a seleção de atributos em *feature stores* garantindo que nenhum colisor ou mediador seja acidentalmente condicionado em etapas de filtragem ou pré-processamento.
5. **Validação de Independências Condicionais e Parcimônia:** verifique se as implicações de independência condicional derivadas do DAG mantêm-se nos dados observados. Adote a parcimônia em colaboração com os especialistas do domínio para evitar grafos densos e não identificáveis.

Conclusão Executiva (“So What?”)

A transição da análise correlacional para a inferência causal baseada em DAGs estabelece uma governança analítica rigorosa sobre a tomada de decisão. A aplicação desse arcabouço previne a alocação ineficiente de capital em subsídios redundantes, ajusta adequadamente as estratégias de precificação e protege as organizações contra os efeitos do viés estrutural. Ao formalizar as hipóteses sobre o mundo real, a inferência causal transforma dados históricos em direcionadores estratégicos seguros, assegurando o crescimento sustentável das operações.